

# Vyhledávání v seznamu

*Úloha:* Zjistěte, zda se v seznamu **a** nachází daná hodnota **x**,  
a pokud ano, tak kde (je-li tam vícekrát, chceme první výskyt).

*Python:*

test výskytu provádí operátor **in**  
nebo také metoda `count()`

```
if x in a  
a.count(x)
```

pozici prvního výskytu určuje metoda `index()`  
(pokud tam není → chyba)

```
a.index(x)
```

*Základní algoritmus:*

jeden průchod polem – časová složitost  $O(N)$

## 1. for-cyklus

```
j = -1
for i in range(len(a)):
    if a[i] == x:
        j = i

if j == -1:
    print("Není tam")
else:
    print("Je na pozici", j)
```

Jednoduché, ale nešikovné (cyklus pokračuje i po nalezení **x**).  
V případě více výskytů najde poslední, nikoliv první výskyt.

## 2. for-cyklus s výskokem

```
j = -1
for i in range(len(a)):
    if a[i] == x:
        j = i
        break

if j == -1:
    print("Není tam")
else:
    print("Je na pozici", j)
```

Obdobné řešení, ale cyklus zbytečně nepokračuje po nalezení **x**.  
V případě více výskytů najde první.

### 3. while-cyklus

```
i = 0
while i < len(a) and a[i] != x:
    i += 1

if i == len(a):
    print("Není tam")
else:
    print("Je na pozici", i)
```

Vhodně zvolená složená podmínka a zkrácené vyhodnocování logických výrazů (zleva doprava, dokud není rozhodnuto o výsledku)

## 4. cyklus řízený proměnou typu boolean

```
i = 0
dalsi = True          #zpracovávat další prvek?
while dalsi:
    if a[i] == x:
        dalsi = False
        print("Je na pozici", i)
    elif i == len(a)-1:
        dalsi = False
        print("Není tam")
    else:
        i += 1
```

## 5. vyhledávání pomocí zarážky

→ zjednodušení podmínky ve while-cyklu

```
a.append(x)                # přidat zarážku (dočasně)
i = 0
while a[i] != x:
    i += 1
del a[-1]                   # zrušit zarážku

if i == len(a):
    print("Není tam")
else:
    print("Je na pozici", i)
```

Hodnota **x** je v seznamu **a** vždy nalezena  
– pokud tam původně nebyla, tak se najde v zarážce.

# Rychlejší vyhledávání

A) dosud: sekvenční průchod daty velikosti  $N \rightarrow$  časová složitost  **$O(N)$**

## B) binární vyhledávání (půlení intervalů)

- data musí být uspořádaná
- vždy porovnat hledanou hodnotu s prostředním prvkem zkoumaného úseku, polovinu úseku „zahodit“
- postupně dostáváme úseky délky  $N, N/2, N/4, N/8, \dots, 1$
- po  $K$  krocích zbývá úsek velikosti  $N/2^K$ , hledáme  $K$  takové, aby  $N/2^K = 1$   
 $\rightarrow$  počet půlení  $K = \log_2 N$ , tedy časová složitost algoritmu  **$O(\log N)$**

*Příklad:* pražský telefonní seznam bytových stanic

- cca 430 000 jmen (v roce 1995)
- rychlost hledajícího člověka 1 jméno za sekundu
- sekvenční hledání: 5 dní a nocí x binární hledání: 20 sekund

## 6. binární vyhledávání

→ půlení intervalů v uspořádaném seznamu

```
i = 0                                # začátek úseku
j = len(a) - 1                       # konec úseku
k = (i + j) // 2                     # střed úseku
while a[k] != x and i <= j:
    if x > a[k]:
        i = k + 1
    else:
        j = k - 1
    k = (i + j) // 2

if x == a[k]:
    print("Je na pozici", k)
else:
    print("Není tam")
```

V případě více výskytů najde některý z nich.



# Řazení dat v poli

= vnitřní třídění (terminologicky nepřesné, ale užívané)

*Úloha:* uspořádat prvky pole podle velikosti  
(od nejmenšího po největší)

## ***Přímé metody***

*SelectSort* – třídění výběrem, přímý výběr

*InsertSort* – třídění vkládáním, přímé zařid'ování

*BubbleSort* – třídění záměnami, bublinkové třídění

- jednoduchý zápis programu
- třídí „na místě“ (tzn. nepotřebují další datovou strukturu velikosti  $N$ )
- časová složitost  $O(N^2)$  → vhodné pro malá data

## ***Rychlejší metody***

*MergeSort* – třídění sléváním

*QuickSort* – třídění rozděllováním

*HeapSort* – třídění haldou, haldové třídění

- časová složitost  $O(N \log N)$

## ***Příhrádkové metody pro data speciálních vlastností***

*CountingSort* – třídění počítáním

*BucketSort* – příhrádkové třídění

*RadixSort* – víceprůchodové příhrádkové třídění

- „lineární“ časová složitost (ale nejen vzhledem k  $N$  – bude později)

*Python*: sám umí řadit

– standardní funkce `sorted()` – vytvoří setříděnou kopii

```
>>> a = [5, 2, 8, 1, 9, 0]
>>> sorted(a)
[0, 1, 2, 5, 8, 9]
>>>
```

- nebo metoda `sort()` – třídí na místě

```
>>> a.sort()
```

- lze řadit seznam čísel podle hodnot  
nebo seznam stringů abecedně

(a také třeba n-tice, slovníky, množiny)

- lze řadit jakékoliv objekty podle vlastního kritéria – parametr `key`

- lze řadit vzestupně nebo sestupně – parametr `reverse`

Použitý algoritmus: *TimSort* (Tim Peters 2002)

- hybridní algoritmus MergeSort / InsertSort
- vyvinuto pro Python, používá také Java
- využívá existence uspořádaných úseků v datech

## SelectSort (třídění výběrem, přímý výběr)

*Algoritmus:*

založíme prázdný výsledný seznam

dokud zadaný vstupní seznam není prázdný

- projdeme vstupní seznam a najdeme v něm nejmenší číslo
- odebereme ho ze seznamu
- a vložíme na konec výsledného uspořádaného seznamu

### *Implementace na místě v poli:*

- pole se dělí na setříděný úsek (vlevo) a neseříděný úsek (vpravo)
- na začátku tvoří všechny prvky neseříděný úsek
- v neseříděném úseku pole se vždy najde nejmenší prvek a vymění se s prvním prvkem tohoto úseku, tím se setříděný úsek prodlouží o jeden prvek

7 4 2 9 5  
2 4 7 9 5  
2 4 7 9 5  
2 4 5 9 7  
2 4 5 7 9

modře – hotovo (setříděný úsek)

červeně – minimum ze zbývajících hodnot

```
def trid_vyberem(a):  
    for i in range(len(a)-1):  
        # umístit číslo na pozici "i"  
        k = i  
        for j in range(i+1, len(a)):  
            if a[j] < a[k]:  
                k = j  
        if k > i:  
            a[k], a[i] = a[i], a[k]
```

## Časová složitost:

- celkem uděláme  $n-1$  průchodů polem
- postupně procházíme úseky délky  $n, n-1, n-2, \dots, 2$
- počet provedených porovnání čísel je tedy postupně  $n-1, n-2, n-3, \dots, 1$
- celkový počet provedených porovnání čísel:  
$$1 + 2 + \dots + (n-2) + (n-1) = n.(n-1)/2$$
- asymptotická časová složitost  $O(n^2)$
- počet provedených záměn čísel v poli je nejvýše  $n-1$ ,  
což časovou složitost neovlivní



# InsertSort (třídění vkládáním, přímé zatříd'ování)

*Algoritmus:*

založíme prázdný výsledný seznam

dokud zadaný vstupní seznam není prázdný

- vezmeme první číslo ze vstupního seznamu
- odebereme ho ze seznamu a vložíme do výsledného uspořádaného seznamu na správné místo, kam patří

### *Implementace na místě v poli:*

- pole se dělí na setříděný úsek (vlevo) a neseříděný úsek (vpravo)
- na začátku je setříděný úsek tvořen pouze prvním prvkem pole
- první prvek neseříděného úseku se vždy zařadí do setříděného úseku na místo, kam patří, tím se setříděný úsek prodlouží o jeden prvek

realizace: prvky setříděného úseku se posouvají o jednu pozici doprava, dokud je třeba

7 4 2 9 5  
4 7 2 9 5  
2 4 7 9 5  
2 4 7 9 5  
2 4 5 7 9

modře – hotovo (setříděný úsek)  
červeně – první ze zbývajících hodnot  
(zatřídňovaný prvek)

```
def trid_vkladanim(a):  
    for i in range(1, len(a)):  
        # vkládáme číslo z pozice "i"  
        x = a[i]  
        j = i-1  
        while j >= 0 and x < a[j]:  
            a[j+1] = a[j]  
            j -= 1  
        a[j+1] = x
```

### *Časová složitost:*

- celkem vykonáme  $n-1$  vkládání čísla (průchodů polem)
  - postupně procházíme úseky délky 1, 2, 3, ...,  $n-1$
  - počet provedených porovnání a posunů čísel v poli je tedy postupně nejvýše 1, 2, 3, ...,  $n-1$   
(může být menší, někdy se neprojde celý úsek)
  - celkový počet provedených operací v nejhorším případě:  
$$1 + 2 + \dots + (n-2) + (n-1) = n.(n-1)/2$$
- asymptotická časová složitost  $O(n^2)$

# BubbleSort (třídění záměnami, bublinkové třídění)

*Základní myšlenka:*

Pole je seřazeno vzestupně právě tehdy, když pro každou dvojici jeho sousedních prvků platí, že levý z nich je menší než pravý (nebo jsou stejné).

*Algoritmus (zároveň implementace na místě v poli):*

- opakovaně procházíme celým polem, porovnáváme sousední prvky a jsou-li špatně, vzájemně je vyměníme
- když při průchodu nenarazíme na žádnou špatnou dvojici sousedů, ukončíme výpočet

.

```
def trid_bublinkove(a):  
    setrideno = False  
    while not setrideno:  
        setrideno = True  
        for j in range(len(a)-1):  
            if a[j] > a[j+1]:  
                a[j], a[j+1] = a[j+1], a[j]  
            setrideno = False
```

*Jiná možnost implementce:*

- každý průchod může být vždy o jeden krok kratší než předchozí (neboť největší prvek tříděného úseku se dostal až na konec úseku)  
→ vždy stačí nejvýše  $N-1$  průchodů

```
def trid_bublinkove(a):  
    for i in range(len(a)-1):      # počítadlo průchodů  
        for j in range(len(a)-i-1):  
            if a[j] > a[j+1]:  
                a[j], a[j+1] = a[j+1], a[j]
```

### Časová složitost:

- celkem vykonáme nejvýše  $n-1$  průchodů polem  
(neboť při každém z nich se alespoň jedno číslo správně umístí)
- postupně procházíme úseky délky  $n, n-1, n-2, \dots, 2$
- počet provedených porovnání a případných prohození čísel je tedy postupně  $n-1, n-2, n-3, \dots, 1$   
(může být menší, někdy se čísla neprohazují, někdy stačí méně průchodů a pole je seřazeno)
- celkový počet provedených operací v nejhorším případě:  
$$1 + 2 + \dots + (n-2) + (n-1) = n.(n-1)/2$$
  
→ asymptotická časová složitost  $O(n^2)$
- časová složitost v nejlepším případě (seřazené vstupní pole) je pouze  $O(n)$  – stačí jeden průchod polem



### *Možnosti dalšího zrychlení:*

- při příštím průchodu polem stačí jít jen do místa poslední uskutečněné výměny  
→ rychlejší zkracování průchodů, stačí méně průchodů

```
def trid_bublinkove(a):  
    vymena = len(a)-1  
    while vymena > 0:  
        pruchod = vymena    # kam až procházíme seznam  
        vymena = 0  
        for j in range(pruchod):  
            if a[j] > a[j+1]:  
                a[j], a[j+1] = a[j+1], a[j]  
                vymena = j    # místo poslední výměny
```

- třídění přetřásáním – pole se prochází střídavě zleva a zprava

# MergeSort (třídění sléváním) – iterativní implementace

- nejprve v poli porovnáme dvojice sousedních prvků a uspořádáme je  
→ dostaneme pole uspořádaných dvojic
- sléváme první a druhou dvojici do uspořádané čtveřice, třetí a čtvrtou dvojici do další uspořádané čtveřice, atd.  
→ dostaneme pole uspořádaných čtveřic
- takto pokračujeme dále, délku uspořádaných úseků zvyšujeme v každém kroku na dvojnásobek: 2, 4, 8, 16, 32, ...
- algoritmus končí, když délka uspořádaného úseku dosáhne  $N$  (tzn. v poli je jediný setříděný úsek)

```

def mergesort(a):
    """
        třídění sléváním - iterativní verze
    """
    n = len(a)          # délka vstupního seznamu
    temp = [None] * n   # alokuje pomocný seznam

    # postupně slévá sousední úseky délek 1,2,4,...
    usek = 1
    while usek < n:
        for zacatek in range(0, n-usek, 2*usek):
            stred = zacatek + usek - 1
            konec = min(stred + usek, n-1)
            merge(a, zacatek, stred, konec, temp)
        usek *= 2

```

```

def merge(a, zac, stred, kon, temp):
    """
        sleje a[zac..stred] s a[stred+1..kon]
        do a[zac..kon] pomocí temp[zac..kon]
    """
    i = zac                # začátek prvního úseku
    j = stred+1            # začátek druhého úseku
    k = zac                # začátek výsledného seznamu

    # sleje a[zac..stred] s a[stred+1..kon] do temp
    while i <= stred and j <= kon:
        if a[i] < a[j]:
            temp[k] = a[i]
            i += 1
        else:
            temp[k] = a[j]
            j += 1
        k += 1

```

```
if i <= stred:      # zbytek prvního úseku
    temp[k:kon+1] = a[i:stred+1]
else:              # zbytek druhého úseku
    temp[k:kon+1] = a[j:kon+1]
```

```
# výsledek zkopíruje zpět do seznamu a
a[zac:kon+1] = temp[zac:kon+1]
```

```
# konec definice funkce merge()
```

*Paměťová složitost:*  $O(N)$

algoritmus potřebuje druhé pomocné pole na slévání úseků, nepracuje tedy „na místě“ jako předchozí algoritmy

*Časová složitost:*

velikost úseků se zdvojnásobuje  $\rightarrow$  provede se  $\log_2 N$  kroků výpočtu, v každém z nich se vykoná práce  $O(N)$ , neboť součet délek všech sléváných úseků je  $N$  a slévání má lineární časovou složitost vzhledem k délce sléváných úseků

$\rightarrow$  celková časová složitost  **$O(N \cdot \log N)$**

# Dolní odhad složitosti problému třídění

## Vstupní data pro úlohu třídění:

- jistá posloupnost  $N$  čísel (klíčů), čísla mohou být navzájem různá
- existuje  $N!$  možných uspořádání vstupních dat velikosti  $N$

## Obecný problém třídění:

o vstupních datech nic nevíme, není předem omezen rozsah hodnot, mohou to být čísla typu float (tzn. nelze jimi indexovat)  
→ při třídění můžeme čísla jedině vzájemně porovnávat

## Strom všech možných průběhů výpočtu

nějakého třídícího algoritmu pro vstupní data velikosti  $N$ :

- kořen = počáteční stav
- binární strom, větvení = porovnání nějakých dvou čísel (dva možné výsledky)
- listy stromu = konec výpočtu (data setříděna)

Pro každá vstupní data se musí průběh výpočtu někde odlišit od ostatních → strom má  **$N!$  listů**.

### **Výška stromu výpočtů $h$**

= počet provedených porovnání čísel při nejdelším výpočtu  
= časová složitost algoritmu v nejhorším případě

Výška úplného binárního stromu se všemi  $K$  listy na poslední hladině je  $\log_2 K$ . Jiný binární strom s  $K$  listy musí mít výšku větší.

Uvažovaný strom všech možných výpočtů má tedy výšku  $h \geq \log_2(N!)$ . Časová složitost libovolného třídícího algoritmu nemůže být proto lepší než  $O(\log_2(N!)) = \mathbf{O(N.log\ N)}$ .

Známe konkrétní algoritmy s časovou složitostí  $O(N.log\ N)$ , např. heapsort nebo mergesort, proto  $O(N.log\ N)$  je i **složitost obecného problému vnitřního třídění v nejhorším případě**.



Přechod  $\log_2(N!) \rightarrow N \cdot \log N$

- podle Stirlingova vzorce

- bez použití Stirlingova vzorce:

$$N! \geq (2k) \cdot (2k-1) \dots (k+1) \cdot k > k^{k+1} \geq k^k = (N/2)^{N/2}$$

pro  $N = 2k$

$$N! \geq (2k+1) \cdot (2k) \dots (k+1) > (k+1/2)^{k+1} > (k+1/2)^{k+1/2} = (N/2)^{N/2}$$

pro  $N = 2k+1$

$$\begin{aligned} h &\geq \log_2(N!) > \log_2((N/2)^{N/2}) = N/2 \cdot \log_2(N/2) = N/2 \cdot (\log_2 N - 1) \geq \\ &\geq N/2 \cdot (\log_2 N / 2) = N/4 \cdot \log_2 N \end{aligned}$$

↑  
neboť  $\log_2 N / 2 \geq 1$  pro  $N \geq 4$

# Třídění s lineární složitostí – přihrádkové metody

- třídíme celá čísla z předem známého rozsahu velikosti  $R$   
( $D$  = dolní mez,  $H$  = horní mez přípustných hodnot,  $R = H - D$ )

nebo třídíme záznamy s takovýmito klíči

- rozsah  $R$  není příliš velký, takže lze vytvořit v paměti seznam délky  $R$   
(bude představovat pole indexované od  $D$  do  $H$ ,  
realizace: posouvání indexů o konstantu  $D$ )

→ lineární časová složitost

- třídění počítáním (*CountingSort*, *CountSort*)
- přihrádkové třídění (*BucketSort*)
- víceprůchodové přihrádkové třídění (*RadixSort*)

# CountingSort (třídění počítáním)

- třídíme pouze celá čísla

*Realizace:*

***a*** – původní seznam čísel délky  $N$

***b*** – setříděný seznam čísel délky  $N$

***c*** – pomocný seznam celých čísel délky  $R$

představuje pole celých čísel s indexy  $D:H$

= čítače výskytů jednotlivých hodnot

- projdeme seznam ***a***,  
do seznamu ***c*** spočítáme počty výskytů jednotlivých hodnot
- projedeme seznam ***c***,  
z uložených hodnot vytvoříme nový obsah seznamu ***b***
- výsledný seznam lze vytvářet v původním poli, kde byl seznam ***a***

```
def trid_pocitanim(a, d, h):  
    c = [0] * (h-d)  
  
    for x in a:  
        c[x-d] += 1  
  
    b = []  
    for i in range(h-d):  
        for j in range(c[i]):  
            b.append(i+d)  
    return b
```